



# 贝叶斯计算及其挑战

Bayesian Computation and some Challenges

博学 慎思 明辨 笃行

何志坚

hezhijian@scut.edu.cn

[www.hezhijian.com.cn](http://www.hezhijian.com.cn)

# 目 录

## contents

- 01.** 贝叶斯与贝叶斯公式
- 02.** 贝叶斯计算方法综述
- 03.** 贝叶斯计算挑战

# 贝叶斯与贝叶斯公式

Part I

贝叶斯学派起源于英国学者贝叶斯在1763年发表的著名论文《论有关机遇问题的求解》

Part II

Part III

$$P(A|D) = P(A) \frac{P(D|A)}{P(D)}$$

Diagram illustrating the components of Bayes' Theorem:

- $P(A|D)$  is labeled as 后验概率 (Posterior Probability).
- $P(A)$  is labeled as 先验概率 (Prior Probability).
- $P(D|A)$  is labeled as 似然函数 (Likelihood Function).
- $P(D)$  is labeled as 证据 (Evidence).




Thomas Bayes 1702-1761

# 贝叶斯公式应用1：三门问题（Monty Hall problem）

Part I

有三扇门，其中一扇有奖品，  
两扇有山羊。选手选完后，主  
持人打开其中一扇有山羊的门，  
主持人问选手是否换另外一扇  
门？



Part II

Part III

$$P(A|D) = P(A) \frac{P(D|A)}{P(D)}$$

A: 选手一开始选中奖品（不换门中奖）

D: 主持人打开其中一扇有山羊的门

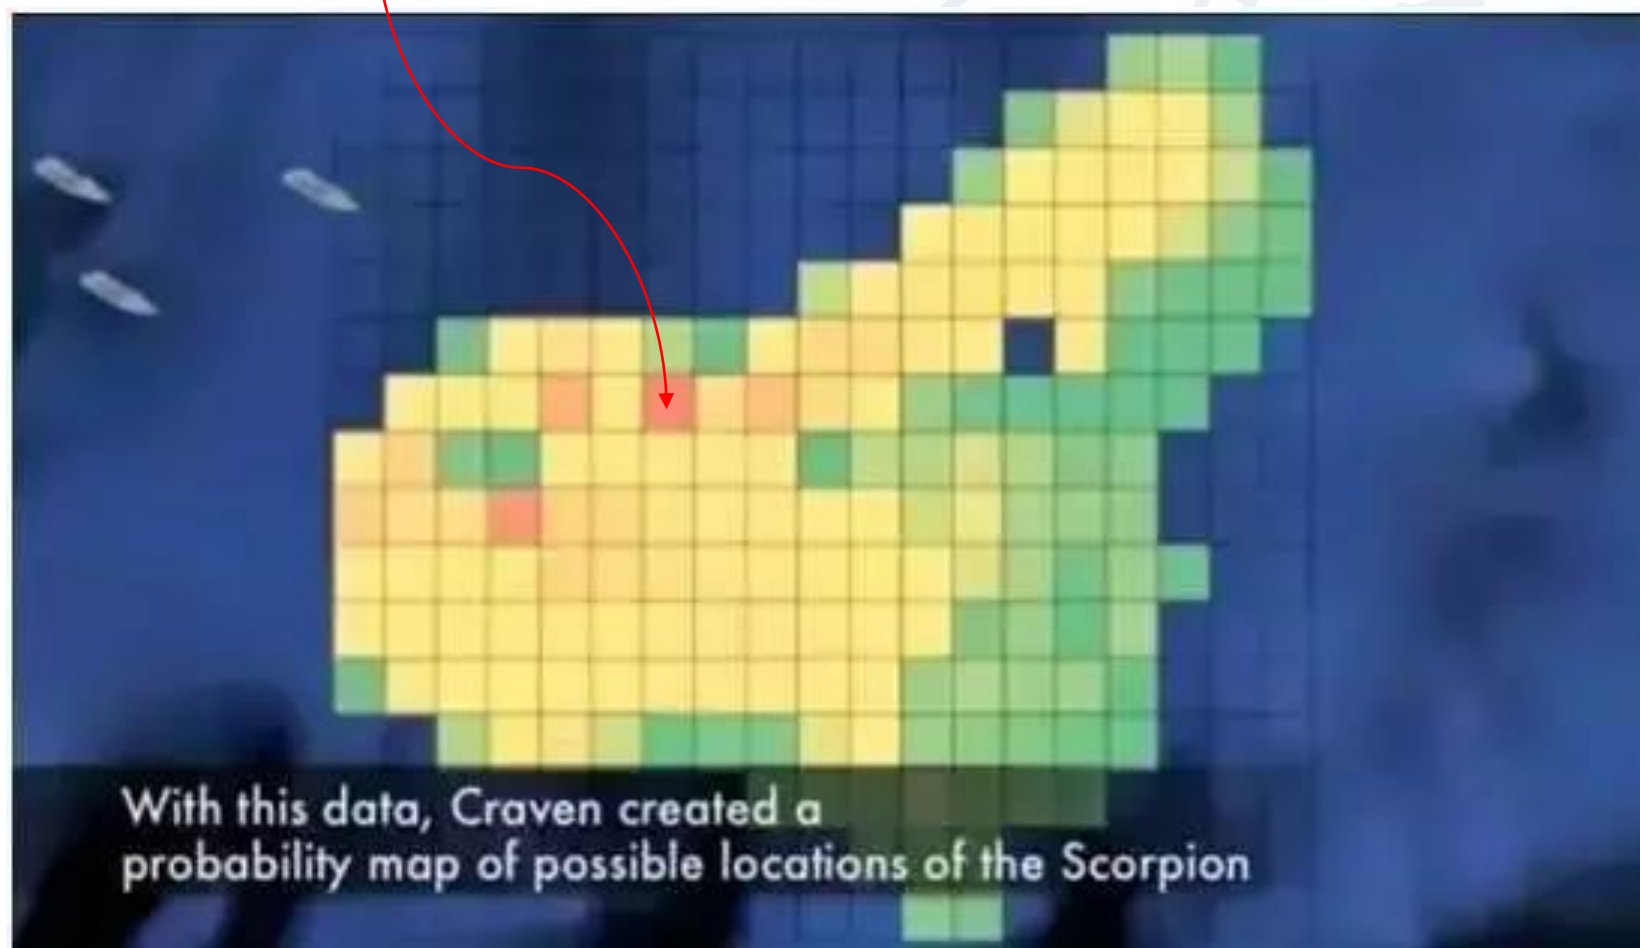
# 贝叶斯公式应用2：天蝎号核潜艇搜救

Part I

$$P(A_i|D) = P(A_i) \frac{P(D|A_i)}{P(D)}$$

Part II

Part III



# 贝叶斯计算的动机

密度形式的贝叶斯公式:

$$p(\theta|\mathbf{y}) = p(\theta) \frac{L(\mathbf{y}|\theta)}{p(\mathbf{y})} \propto p(\theta)L(\mathbf{y}|\theta)$$

后验分布

先验分布

似然函数

证据

$\theta = (\theta_1, \dots, \theta_d)$ :  
模型参数

$\mathbf{y} = (y_1, \dots, y_n)$ :  
观测数据

$$p(\mathbf{y}) = \int p(\theta)L(\mathbf{y}|\theta)d\theta$$

一般情况下,  $p(\mathbf{y})$ 不可计算

Part I

Part II

Part III



# 感兴趣的问题

Part I

$$E[f(\theta)|\mathbf{y}] = \int f(\theta)p(\theta|\mathbf{y})d\theta$$

Part II

- 后验均值
- 后验概率

Part III

- $\because p(\theta|\mathbf{y})$ 未知
- $\therefore E[f(\theta)|\mathbf{y}]$ 未知



需要引入数值算法!

# 贝叶斯计算：从1763年到21世纪

Part I

$$E[f(\theta)|\mathbf{y}] = \int f(\theta)p(\theta|\mathbf{y})d\theta$$

Part II

- 1774年, Laplace积分逼近方法
- 1953年, 蒙特卡洛(Monte Carlo)方法和Metropolis算法
- 1964年, 重要性抽样(Importance Sampling)方法
- 1970年, 推广的Metropolis算法——Metropolis-Hastings算法
- 1980s, Gibbs抽样方法
- 21世纪: 第二次计算革命 (面临一些新挑战)

Part III



Part I

$$p(\theta|\mathbf{y}) = p(\theta) \frac{L(\mathbf{y}|\theta)}{p(\mathbf{y})} \propto p(\theta)L(\mathbf{y}|\theta)$$

Part II

**挑战一：** 似然函数 $L(\mathbf{y}|\theta)$ 没有显示表达式

- 分位数模型, 生成模型  $\mathbf{y} = G(\mathbf{v}|\theta)$ ,  $\mathbf{v}$ 是随机向量
- 一些深度学习模型
- 隐马尔科夫模型(HMM)

Part III

Part I

$$p(\theta|\mathbf{y}) = p(\theta) \frac{L(\mathbf{y}|\theta)}{p(\mathbf{y})} \propto p(\theta)L(\mathbf{y}|\theta)$$

Part II

**挑战二：** 似然函数 $L(\mathbf{y}|\theta)$ 计算复杂度高

Part III

- $\mathbf{y} = (y_1, \dots, y_n)$ 数据量为 $n$ , 似然函数复杂度为 $O(n)$
- 对大数据问题不可扩展(not scalable)

Part I

$$p(\theta|\mathbf{y}) = p(\theta) \frac{L(\mathbf{y}|\theta)}{p(\mathbf{y})} \propto p(\theta)L(\mathbf{y}|\theta)$$

Part II

**挑战三：** 高维参数  $\theta = (\theta_1, \dots, \theta_d)$

- 潜(冗余)变量的存在,  $d > n$
- 对大数据问题不可扩展(not scalable)

Part III

# 例子：状态空间模型(隐马尔科夫模型)

两个随机过程 $\{X_t\}_{t \geq 0}, \{Y_t\}_{t \geq 0}$

- $\{X_t\}_{t \geq 0}$  是马尔科夫过程(不可观测, 潜变量)

$$X_0 \sim \mu_\theta(x_0), \quad X_t | X_0, \dots, X_{t-1} \sim f_\theta(x_t | x_{t-1})$$

- $\{Y_t\}_{t \geq 0}$  是可观测的随机过程, 满足

$$Y_t | X_0, \dots, X_t, Y_0, \dots, Y_{t-1} \sim g_\theta(y_t | x_t)$$

- $\theta$  是模型参数

# 例子：状态空间模型(隐马尔科夫模型)

■ 观测数据  $y_{0:T} = (y_0, y_1, \dots, y_T)$

■ 如何推断马尔科夫过程  $x_{0:T} = (x_0, x_1, \dots, x_T)$ ?

■ 如何估计模型参数  $\theta$

似然函数

高维积分, 通常无解析解!

$$\begin{aligned} p_{\theta}(y_{0:T}) &= \int p_{\theta}(x_{0:T}, y_{0:T}) dx_{0:T} \\ &= \int \mu_{\theta}(x_0) \prod_{t=1}^T f_{\theta}(x_t | x_{t-1}) \prod_{t=0}^T g_{\theta}(y_t | x_t) dx_{0:T} \end{aligned}$$

若数据不断累积( $T$ 变大), 如何设计算法? **Off-line or on-line?**

Part I

Part II

Part III

Part I

$$p(\theta|\mathbf{y}) = p(\theta) \frac{L(\mathbf{y}|\theta)}{p(\mathbf{y})} \propto p(\theta)L(\mathbf{y}|\theta)$$

Part II

**方法一：** 伪边际方法(Pseudo-Marginal Methods)

- 目标分布 $p(\theta, \mathbf{x}|\mathbf{y})$
- $\mathbf{z}$ : 潜变量或者人工变量 (用于估计似然函数 $L(\mathbf{y}|\theta)$ )

Part III



Part I

$$p(\theta|\mathbf{y}) = p(\theta) \frac{L(\mathbf{y}|\theta)}{p(\mathbf{y})} \propto p(\theta)L(\mathbf{y}|\theta)$$

Part II

**方法二：** 近似贝叶斯计算  
(Approximate Bayesian Computation, ABC)

Part III

- 目标分布  $p_h(\theta, \mathbf{z}|\mathbf{y}) \rightarrow p(\theta, \mathbf{z}|\mathbf{y})$  当  $h \rightarrow 0$  时。
- 这是一种近似算法，得到不是准确的后验分布

Part I

$$p(\theta|\mathbf{y}) = p(\theta) \frac{L(\mathbf{y}|\theta)}{p(\mathbf{y})} \propto p(\theta)L(\mathbf{y}|\theta)$$

Part II

**方法三：**变分贝叶斯(Variational Bayes)

- 在给定分布族中找一种 “最优” 分布来近似后验分布 $p(\theta|\mathbf{y})$

Part III

$$q^*(\boldsymbol{\theta}) := \arg \min_{q(\boldsymbol{\theta}) \in \mathcal{Q}} \text{KL} [q(\boldsymbol{\theta})|p(\boldsymbol{\theta}|\mathbf{y})]$$

- Kullback-Leibler (KL) 散度,  $KL(q|p) = E_q[\log(\frac{q(\theta)}{p(\theta|y)})]$

Part I

**方法四**：粒子滤波算法(Particle Filtering), 也叫序贯蒙特卡罗方法(sequential Monte Carlo)

Part II



- 通过采样, 用离散分布近似

Part III

$$\hat{p}_{\theta}(y_{0:T}) = \hat{p}_{\theta}(y_0) \prod_{t=1}^T \hat{p}_{\theta}(y_t | y_{0:t-1})$$

# 基于随机模拟的计算方法：蒙特卡罗方法

## 工作机制：



$$\hat{I}_n = \frac{1}{n} \sum_{i=1}^n f(X_i) \approx E[f(X)]$$

## 一些性质：

- 收敛阶为  $O(n^{-0.5})$ ，与维数  $d$  无关，与  $f(X)$  光滑性无关。
- 收敛阶太低，往往不满足实际需求。

Part I

Part II

Part III

# 拟蒙特卡罗方法(QMC)

Part I

$$\int_{(0,1)^d} f(\mathbf{u}) d\mathbf{u} \approx \frac{1}{n} \sum_{i=1}^n f(\mathbf{u}_i)$$

## 蒙特卡罗方法

### Monte Carlo (MC)

- 使用独立同分布点列（伪随机数）
- 收敛阶 $O(n^{-1/2})$

Part II

## 拟蒙特卡罗方法

### Quasi-Monte Carlo (QMC)

- 使用**确定性的超均匀（低偏差）序列**
- **高阶**算法


Part III

- 华罗庚和王元提出被国际上誉为“**华—王方法**”
- Halton序列, Sobol序列, Faure序列, Niederreiter序列, 好格子点列
- 基于数论工具, 其**机理与蒙特卡罗不同**



# 随机化拟蒙特卡罗方法(RQMC)

实际应用中，使用**随机化拟蒙特卡罗(RQMC)**：无偏估计、容易估计误差



为什么使用RQMC?

- ① 对于一般的函数，RQMC渐近快于MC： $o(n^{-1/2})$  vs.  $O(n^{-1/2})$  **不会变差**
- ② 函数越光滑，RQMC的收敛阶越高
  - 有界变差的函数： $O(n^{-1} (\log n)^d)$  **有可能得到更高收敛阶**
  - 偏导平方可积的函数： $O(n^{-3/2} (\log n)^{(d-1)/2})$





# Thanks for your attention

何志坚

hezhijian@scut.edu.cn